Московский Государственный Технический Университет имени Н.Э.Баумана

Факультет Информатика и системы управления

Кафедра ИУ-5 «Системы обработки информации и управления»

Отчёт по рубежному контролю № 1

По дисципление

«Методы Машинного Обучения»

Группа ИУ5И-22М

Лю Ань

Москва 2023г

Номер варианта: 20

Номер задачи №1: 20

Для набора данных проведите масштабирование данных для одного (произвольного) числового признака с использованием MinMax-масштабирования.

Загрузить данные

Задача1.Для набора данных проведите масштабирование данных для одного (произвольного) числового признака с использованием MinMax-масштабирования.

```
[13] #Масштабирование признаков
     import pandas as pd
     import matplotlib.pyplot as plt
     import numpy as np
     import seaborn as sns
     from sklearn.datasets import fetch_california_housing
     from sklearn.model_selection import train_test_split
     from sklearn.preprocessing import StandardScaler
     from sklearn.preprocessing import MinMaxScaler
     from sklearn.preprocessing import RobustScaler
     from sklearn.preprocessing import MaxAbsScaler
```

```
#MinMax-масштабирование
# Обучаем StandardScaler на всей выборке и масштабируем
housing = fetch_california_housing()
data = pd.DataFrame(housing.data,
                                        columns=housing.feature_names)
data['Y'] = housing.target
data.shape
```

```
(20640, 9)
```

```
[15] X_ALL = data.drop('Y', axis=1)
```

```
[16] def arr_to_df(arr_scaled):
         res = pd.DataFrame(arr_scaled, columns=X_ALL.columns)
         return res
```

```
[17] X_train, X_test, y_train, y_test = train_test_split(X_ALL, data['Y'],
                                                         test_size=0.2,
                                                         random_state=1)
     # Преобразуем массивы в DataFrame
     X_train_df = arr_to_df(X_train)
     X_test_df = arr_to_df(X_test)

     X_train_df.shape, X_test_df.shape
```

```
((16512, 8), (4128, 8))
```

Метод " MinMax-масштабирования"

```
cs31 = MinMaxScaler()
data_cs31_scaled_temp = cs31.fit_transform(X_ALL)
# формируем DataFrame на основе массива
data_cs31_scaled = arr_to_df(data_cs31_scaled_temp)
data_cs31_scaled.describe()
```

	MedInc	HouseAge	AveRooms	AveBedrms	Population	AveOccup	Latitude	Longitude
count	20640.000000	20640.000000	20640.000000	20640.000000	20640.000000	20640.000000	20640.000000	20640.000000
mean	0.232464	0.541951	0.032488	0.022629	0.039869	0.001914	0.328572	0.476125
std	0.131020	0.246776	0.017539	0.014049	0.031740	0.008358	0.226988	0.199555
min	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
25%	0.142308	0.333333	0.025482	0.019943	0.021974	0.001398	0.147715	0.253984
50%	0.209301	0.549020	0.031071	0.021209	0.032596	0.001711	0.182784	0.583665
75%	0.292641	0.705882	0.036907	0.022713	0.048264	0.002084	0.549416	0.631474
max	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000

```
[19] cs32 = MinMaxScaler()
cs32.fit(X_train)
data_cs32_scaled_train_temp = cs32.transform(X_train)
data_cs32_scaled_test_temp = cs32.transform(X_test)
# формируем DataFrame на основе массива
data_cs32_scaled_train = arr_to_df(data_cs32_scaled_train_temp)
data_cs32_scaled_test = arr_to_df(data_cs32_scaled_test_temp)
```

```
# Построение плотности распределения
def draw_kde(col_list, df1, df2, label1, label2):
        fig, (ax1, ax2) = plt.subplots(
                ncols=2, figsize=(12, 5))
        # первый график
        ax1.set_title(label1)
        sns.kdeplot(data=df1[col_list], ax=ax1)
        # второй график
        ax2.set_title(label2)
        sns.kdeplot(data=df2[col_list], ax=ax2)
        plt.show()
```

```
draw_kde(['Population', 'AveRooms', 'Longitude'], data, data_cs31_scaled, 'до масштабирования', 'после масштабирования')
```

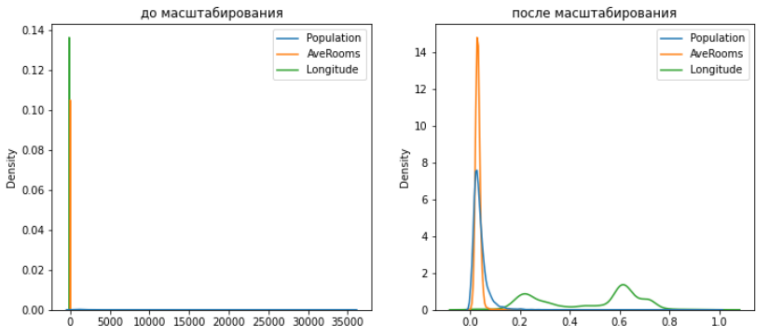

```
draw_kde(['Population', 'AveRooms', 'Longitude'], data_cs32_scaled_train, data_cs32_scaled_test, 'обучающая', 'тестовая')
```

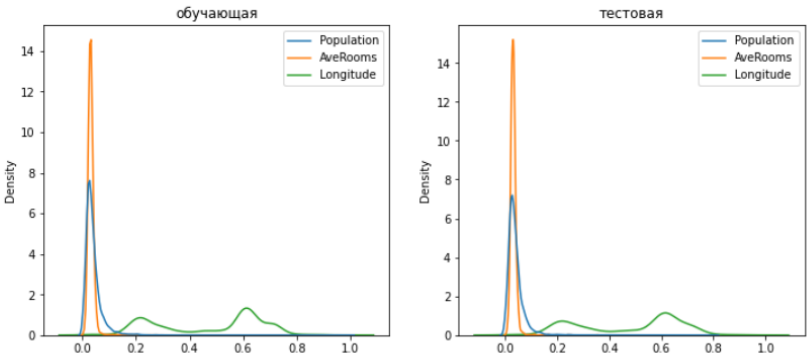

Номер задачи №2: 40

Для набора данных проведите процедуру отбора признаков (feature selection). Используйте метод на основе корреляции признаков.

```
# Формирование DataFrame с сильными корреляциями
def make_corr_df(df):
        cr = data.corr()
        cr = cr.abs().unstack()
        cr = cr.sort_values(ascending=False)
        cr = cr[cr >= 0.8]
        cr = cr[cr < 1]
        cr = pd.DataFrame(cr).reset_index()
        cr.columns = ['f1', 'f2', 'corr']
        return cr
```

```
[26] make_corr_df(data)
```

	f1	f2	corr
0	Longitude	Latitude	0.924664
1	Latitude	Longitude	0.924664
2	AveRooms	AveBedrms	0.847621
3	AveBedrms	AveRooms	0.847621

```
# Обнаружение групп коррелирующих признаков
def corr_groups(cr):
        grouped_feature_list = []
        correlated_groups = []

        for feature in cr['f1'].unique():
                if feature not in grouped_feature_list:
                        # находим коррелирующие признаки
                        correlated_block = cr[cr['f1'] == feature]
                        cur_dups = list(correlated_block['f2'].unique()) + [feature]
                        grouped_feature_list = grouped_feature_list + cur_dups
                        correlated_groups.append(cur_dups)
        return correlated_groups
```

```
[28] # Группы коррелирующих признаков
corr_groups(make_corr_df(data))
```

```
[['Latitude', 'Longitude'], ['AveBedrms', 'AveRooms']]
```

```
sns.heatmap(data.corr(),  annot=True,  fmt='.3f')
```

<Axes: >

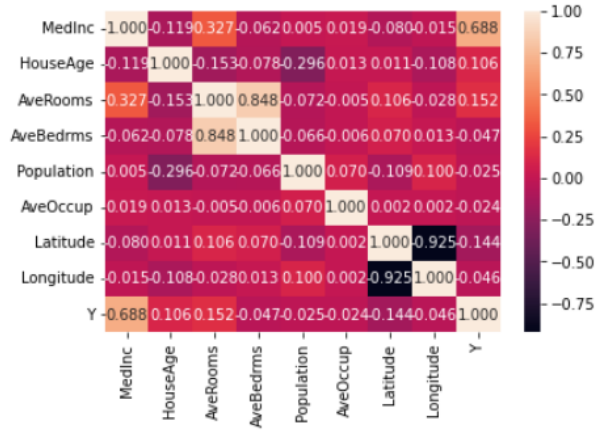

Дополнительные требования по группам:

Для студентов групп ИУ5-22М, ИУ5И-22М - для произвольной колонки данных построить гистограмму.

```
fig, ax = plt.subplots(figsize=(10, 10))
sns.distplot(data['MedInc'])
```

```
<ipython-input-32-46ea8e7e1a1b>:2: UserWarning:

`distplot` is a deprecated function and will be removed in seaborn v0.14.0.

Please adapt your code to use either `displot` (a figure-level function with
similar flexibility) or `histplot` (an axes-level function for histograms).

For a guide to updating your code to use the new functions, please see
https://gist.github.com/mwaskom/de44147ed2974457ad6372750bbe5751

  sns.distplot(data['MedInc'])
<Axes: xlabel='MedInc', ylabel='Density'>
```